

ProblemarioU4

November 27, 2025

Analiza los siguientes diseños experimentales, e intenta sacar el máximo valor a la información. Verifica los supuestos (linealidad, homocedasticidad e independencia), puedes apoyarte en [este documento](#). Aplica una prueba post-hoc en caso que sea necesario. Redacta una conclusión y una recomendación para las personas que recolectaron los datos.

1. **Comparación de cuatro métodos de ensamble:** Un equipo de mejora investiga el efecto de cuatro métodos de ensamble A, B, C y D, sobre el tiempo de ensamble en minutos. En primera instancia, la estrategia experimental es aplicar cuatro veces los cuatro métodos de ensamble en orden completamente aleatorio (las 16 pruebas en orden aleatorio). Los tiempos de ensamble obtenidos se muestran en la tabla 3.1. Si se usa el diseño completamente al azar (DCA), se supone que, además del método de ensamble, no existe ningún otro factor que influya de manera significativa sobre la variable de respuesta (tiempo de ensamble).

Método de ensamble	A	B	C	D
	6	7	11	10
	8	9	16	12
	7	10	11	11
	8	8	13	9

```
[1]: #BLANCA ROCIO SILVA GALLEGOS
# csv es un acrónimo de "comma separated values" o "valores separados por"
#      ↪comas".
# Lo primero que hay que hacer es pasar estos datos a una tabla de valores
#      ↪crudos
# en formato csv. Recuerden el problema que fue usar espacios en el csv, por
#      ↪esta
# razón, evítenlos.

import pandas as pd
from io import StringIO

datos = '''
metodo,tiempo
A,6
A,8
A,7
A,8
```

```

B,7
B,9
B,10
B,8
C,11
C,16
C,11
C,13
D,10
D,12
D,11
D,9
'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df
# De aquí en adelante, ya se lo dejo a ustedes.

```

```

[1]:
metodo  tiempo
0      A      6
1      A      8
2      A      7
3      A      8
4      B      7
5      B      9
6      B     10
7      B      8
8      C     11
9      C     16
10     C     11
11     C     13
12     D     10
13     D     12
14     D     11
15     D      9

```

```

[2]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías

```

```

modelo_lineal = ols(f'tiempo ~ C(metodo)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova

```

```

[2]:

```

	sum_sq	df	F	PR(>F)
C(metodo)	69.5	3.0	9.423729	0.001771
Residual	29.5	12.0	NaN	NaN

```

[3]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo_lineal.resid

# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()


# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()


```

```

valor-p (Shapiro) = 0.2808008139238357

```





```
[4]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['metodo'] == 'A']['tiempo']
grupo2 = df[df['metodo'] == 'B']['tiempo']
grupo3 = df[df['metodo'] == 'C']['tiempo']
grupo4 = df[df['metodo'] == 'D']['tiempo']

stat, p = levene(grupo1, grupo2, grupo3, grupo4)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.4485146502776487

```
[5]: #BLANCA ROCIO SILVA GALLEGOS
# Si no se cumple el supuesto de normalidad o el de homoscedasticidad
from scipy.stats import boxcox
import matplotlib.pyplot as plt

# Transformación mediante el método box-cox
# Solo funciona si Y > 0
```


```

df["respuesta_boxcox"], lambda_opt = boxcox(df["tiempo"])
print(f"Lambda óptimo: {lambda_opt}")

plt.figure(figsize = (5, 5), dpi = 100)
plt.scatter(df["tiempo"], df["respuesta_boxcox"], color = "black")
plt.title("Variable trasformada mediante Box-Cox")
plt.xlabel("Variable real")
plt.ylabel("Variable trasformada")
plt.show()

```

Lambda óptimo: -0.2809888705290132



```

[6]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

```

```
# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'respuesta_boxcox ~ C(metodo)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[6]:
```

	sum_sq	df	F	PR(>F)
C(metodo)	0.202435	3.0	10.789983	0.001006
Residual	0.075046	12.0	NaN	NaN

```
[7]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

```
valor-p (Shapiro) = 0.5124442012773083
```





```
[8]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['metodo'] == 'A']['respuesta_boxcox']
grupo2 = df[df['metodo'] == 'B']['respuesta_boxcox']
grupo3 = df[df['metodo'] == 'C']['respuesta_boxcox']
grupo4 = df[df['metodo'] == 'D']['respuesta_boxcox']

stat, p = levene(grupo1, grupo2, grupo3, grupo4)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.9372028709850322

```
[9]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['respuesta_boxcox'], groups=df['metodo'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="Métodos", xlabel="Respuesta_boxcox")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj  lower  upper  reject
-----
    A     B   0.0881 0.4275  -0.078  0.2541   False
    A     C   0.2967 0.0009   0.1307  0.4627    True
    A     D   0.2029 0.0158   0.0369  0.3689    True
    B     C   0.2086 0.0132   0.0426  0.3746    True
    B     D   0.1148 0.2228  -0.0512  0.2808   False
    C     D  -0.0938 0.3761  -0.2598  0.0722   False
-----

```

[9]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



```
[10]: #BLANCA ROCIO SILVA GALLEGOS
# 2 (eta cuadrado)          Tamaño del efecto
# ~0.01                      Pequeño
# ~0.06                      Mediano
# ~0.14 o más               Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un 2 de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(metodo)'] / tabla_anova['sum_sq'].sum()
print(f" 2 (tamaño de efecto): {eta_squared:.3f}")
```

² (tamaño de efecto): 0.730

Métodos de ensamble

Conclusión general:

Existen diferencias reales entre algunos métodos de ensamble. Los resultados de Shapiro y Levene indicaron que los supuestos estadísticos se cumplieron, y la prueba de Tukey confirmó que no todos los métodos producen el mismo tiempo de ensamble. En general, el método C se comporta de forma distinta, mientras que A, B y D presentan resultados más similares y estables.

2. **Comparación de cuatro tipos de cuero:** Un fabricante de calzado desea mejorar la calidad de las suelas, las cuales se pueden hacer con uno de los cuatro tipos de cuero A, B, C y D disponibles en el mercado. Para ello, prueba los cueros con una máquina que hace pasar los zapatos por una superficie abrasiva; la suela de éstos se desgasta al pasarla por dicha superficie. Como criterio de desgaste se usa la pérdida de peso después de un número fijo de ciclos. Se prueban en orden aleatorio 24 zapatos, seis de cada tipo de cuero. Al hacer las pruebas en orden completamente al azar se evitan sesgos y las mediciones en un tipo de cuero resultan independientes de las demás. Los datos (en miligramos) sobre el desgaste de cada tipo de cuero se muestran en la tabla.

Tipo de cuero	Observaciones	Promedio
A	264, 260, 258, 241, 262, 255	256.7
B	208, 220, 216, 200, 213, 206	209.8
C	220, 263, 219, 225, 230, 228	230.8
D	217, 226, 215, 227, 220, 222	220.7

```
[11]: #BLANCA ROCIO SILVA GALLEGOS
import pandas as pd
from io import StringIO
```

```

datos = '''
tipo,observaciones
A,264
A,260
A,258
A,241
A,262
A,255
B,208
B,220
B,216
B,200
B,213
B,206
C,220
C,263
C,219
C,225
C,230
C,228
D,217
D,226
D,215
D,227
D,220
D,222
'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df

```

```

[11]:
   tipo  observaciones
0     A             264
1     A             260
2     A             258
3     A             241
4     A             262
5     A             255
6     B             208
7     B             220
8     B             216
9     B             200
10    B             213
11    B             206
12    C             220

```

13	C	263
14	C	219
15	C	225
16	C	230
17	C	228
18	D	217
19	D	226
20	D	215
21	D	227
22	D	220
23	D	222

```
[12]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'observaciones ~ C(tipo)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[12]:
```

	sum_sq	df	F	PR(>F)
C(tipo)	7019.458333	3.0	22.755356	0.000001
Residual	2056.500000	20.0	NaN	NaN

```
[13]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")


# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
```

```
plt.title("Histograma de residuos")  
plt.show()
```

valor-p (Shapiro) = 0.00967014513830024





```
[14]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['tipo'] == 'A']['observaciones']
grupo2 = df[df['tipo'] == 'B']['observaciones']
grupo3 = df[df['tipo'] == 'C']['observaciones']
grupo4 = df[df['tipo'] == 'D']['observaciones']

stat, p = levene(grupo1, grupo2, grupo3, grupo4)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.6351342635286297


```
[15]: #BLANCA ROCIO SILVA GALLEGOS
# Si no se cumple el supuesto de normalidad o el de homoscedasticidad
from scipy.stats import boxcox
import matplotlib.pyplot as plt

# Transformación mediante el método box-cox
# Solo funciona si Y > 0
```

```
df["observaciones_boxcox"], lambda_opt = boxcox(df["observaciones"])
print(f"Lambda óptimo: {lambda_opt}")

plt.figure(figsize = (5, 5), dpi = 100)
plt.scatter(df["observaciones"], df["observaciones_boxcox"], color = "black")
plt.title("Variable trasformada mediante Box-Cox")
plt.xlabel("Variable real")
plt.ylabel("Variable trasformada")
plt.show()
```

Lambda óptimo: -3.707788382033557



```
[16]: #BLANCA ROCIO SILVA GALLEGOS
df
```

```
[16]:
```

	tipo	observaciones	observaciones_boxcox
0	A	264	0.269703
1	A	260	0.269703

2	A	258	0.269703
3	A	241	0.269703
4	A	262	0.269703
5	A	255	0.269703
6	B	208	0.269703
7	B	220	0.269703
8	B	216	0.269703
9	B	200	0.269703
10	B	213	0.269703
11	B	206	0.269703
12	C	220	0.269703
13	C	263	0.269703
14	C	219	0.269703
15	C	225	0.269703
16	C	230	0.269703
17	C	228	0.269703
18	D	217	0.269703
19	D	226	0.269703
20	D	215	0.269703
21	D	227	0.269703
22	D	220	0.269703
23	D	222	0.269703

```
[17]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'observaciones_boxcox ~ C(tipo)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[17]:
```

	sum_sq	df	F	PR(>F)
C(tipo)	3.735519e-19	3.0	23.368221	9.595697e-07
Residual	1.065698e-19	20.0	NaN	NaN

```
[18]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo_lineal.resid
```

```


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")


# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()

```

valor-p (Shapiro) = 0.4576953738713335





```
[19]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['tipo'] == 'A']['observaciones_boxcox']
grupo2 = df[df['tipo'] == 'B']['observaciones_boxcox']
grupo3 = df[df['tipo'] == 'C']['observaciones_boxcox']
grupo4 = df[df['tipo'] == 'D']['observaciones_boxcox']

stat, p = levene(grupo1, grupo2, grupo3, grupo4)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.3428159311494669

```
[20]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05
```

```

# Prueba de Tukey
tukey = pairwise_tukeyhsd(endog=df['observaciones_boxcox'], groups=df['tipo'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="tipo", xlabel="observaciones_boxcox")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj  lower upper reject
-----
    A      B    -0.0    0.0  -0.0  -0.0    True
    A      C    -0.0 0.0048  -0.0  -0.0    True
    A      D    -0.0 0.0001  -0.0  -0.0    True
    B      C     0.0 0.0018   0.0   0.0    True
    B      D     0.0 0.0613  -0.0   0.0   False
    C      D    -0.0 0.401   -0.0   0.0   False
-----

```

[20]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



```
[21]: #BLANCA ROCIO SILVA GALLEGOS
# 2 (eta cuadrado)      Tamaño del efecto
# ~0.01                  Pequeño
# ~0.06                  Mediano
# ~0.14 o más           Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un 2 de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(tipo)'] / tabla_anova['sum_sq'].sum()
print(f"2 (tamaño de efecto): {eta_squared:.3f}")
```

² (tamaño de efecto): 0.778

B Y D no tiene difrenecia significativa y elegir de preferencia B

Tipos de cuero

Conclusión general:

Se comprobó que el tipo de cuero influye significativamente en el desgaste. Inicialmente no se cumplió el supuesto de normalidad, por lo que fue necesaria la transformación Box-Cox. Después de ajustar los datos, Tukey mostró que algunos tipos de cuero se comportan de manera similar

(especialmente B y D), mientras que otros presentan diferencias claras. En general, el tipo de cuero impacta directamente la durabilidad de la suela.

3. En un centro de investigación se realiza un estudio para comparar varios tratamientos que, al aplicarse previamente a los frijoles crudos, reducen su tiempo de cocción. Estos tratamientos son a base de bicarbonato de sodio y cloruro de sodio o sal común. El primer tratamiento (T_1) es el de control, que consiste en no aplicar ningún tratamiento. El tratamiento T_2 es el remojo en agua con bicarbonato de sodio, el T_3 es remojar en agua con sal común y el T_4 es remojar en agua con una combinación de ambos ingredientes en proporciones iguales. La variable de respuesta es el tiempo de cocción en minutos. Los datos se muestran en la siguiente tabla:

T_1	T_2	T_3	T_4
213	76	57	84
214	85	67	82
204	74	55	85
208	78	64	92
212	82	61	87
200	75	63	79
207	82	63	90

[22]: *#BLANCA ROCIO SILVA GALLEGOS*

```
import pandas as pd
from io import StringIO
```

```
datos = '''
tratamiento,tiempo
t1,213
t2,76
t3,57
t4,84
t1,214
t2,85
t3,67
t4,82
t1,204
t2,74
t3,55
t4,85
t1,208
t2,78
t3,64
t4,92
t1,212
t2,82
t3,61
t4,87
```

```

t1,200
t2,75
t3,63
t4,79
t1,207
t2,82
t3,63
t4,90

'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df

```

```

[22]:

```

	tratamiento	tiempo
0	t1	213
1	t2	76
2	t3	57
3	t4	84
4	t1	214
5	t2	85
6	t3	67
7	t4	82
8	t1	204
9	t2	74
10	t3	55
11	t4	85
12	t1	208
13	t2	78
14	t3	64
15	t4	92
16	t1	212
17	t2	82
18	t3	61
19	t4	87
20	t1	200
21	t2	75
22	t3	63
23	t4	79
24	t1	207
25	t2	82
26	t3	63
27	t4	90

```
[23]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'tiempo ~ C(tratamiento)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[23]:
```

	sum_sq	df	F	PR(>F)
C(tratamiento)	95041.250000	3.0	1558.966022	1.260640e-27
Residual	487.714286	24.0	NaN	NaN

```
[24]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

```
valor-p (Shapiro) = 0.34689165649615683
```





```
[25]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['tratamiento'] == 't1']['tiempo']
grupo2 = df[df['tratamiento'] == 't2']['tiempo']
grupo3 = df[df['tratamiento'] == 't3']['tiempo']
grupo4 = df[df['tratamiento'] == 't4']['tiempo']

stat, p = levene(grupo1, grupo2, grupo3, grupo4)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.9201477397132211

```
[26]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['tiempo'], groups=df['tratamiento'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="tratamiento", xlabel="tiempo")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")


```

```

Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====
group1 group2  meandiff p-adj    lower    upper  reject
-----
   t1    t2 -129.4286   0.0 -136.0757 -122.7815   True
   t1    t3 -146.8571   0.0 -153.5043  -140.21    True
   t1    t4 -122.7143   0.0 -129.3614 -116.0672   True
   t2    t3  -17.4286   0.0  -24.0757  -10.7815   True
   t2    t4   6.7143 0.0471   0.0672  13.3614   True
   t3    t4  24.1429   0.0  17.4957   30.79    True
-----

```

[26]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



```
[27]: #BLANCA ROCIO SILVA GALLEGOS
# 2 (eta cuadrado)          Tamaño del efecto
# ~0.01                      Pequeño
# ~0.06                      Mediano
# ~0.14 o más                Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un 2 de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(tratamiento)'] / tabla_anova['sum_sq'].
    ↪sum()
print(f"2 (tamaño de efecto): {eta_squared:.3f}")
```

² (tamaño de efecto): 0.995

Tratamientos para frijoles

Conclusión general:

Los tratamientos aplicados antes de la cocción afectan de manera significativa el tiempo de cocción. Las pruebas de Shapiro y Levene confirmaron que los datos cumplían los supuestos estadísticos, y la prueba de Tukey mostró diferencias claras entre todos los tratamientos. En general, los tratamientos químicos reducen considerablemente el tiempo de cocción respecto al control.

4. Para estudiar la confiabilidad de ciertos tableros electrónicos para carros, se someten a un envejecimiento acelerado durante 100 horas a determinada temperatura, y como variable de interés se mide la intensidad de corriente que circula entre dos puntos, cuyos valores aumentan con el deterioro. Se probaron 20 módulos repartidos de manera equitativa en cinco temperaturas y los resultados obtenidos fueron los siguientes:

20°C	40°C	60°C	80°C	100°C
15	17	23	28	45
18	21	19	32	51
13	11	25	34	57
12	16	22	31	48

```
[28]: #BLANCA ROCIO SILVA GALLEGOS
import pandas as pd
from io import StringIO

datos = '''
grados,numero
20°,15
```

```

40°,17
60°,23
80°,28
100°,45
20°,18
40°,21
60°,19
80°,32
100°,51
20°,13
40°,11
60°,25
80°,34
100°,57
20°,12
40°,16
60°,22
80°,31
100°,48
'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df

```

```

[28]:
   grados  numero
0      20°      15
1      40°      17
2      60°      23
3      80°      28
4     100°      45
5      20°      18
6      40°      21
7      60°      19
8      80°      32
9     100°      51
10     20°      13
11     40°      11
12     60°      25
13     80°      34
14    100°      57
15     20°      12
16     40°      16
17     60°      22
18     80°      31
19    100°      48

```

```
[29]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'numero ~ C(grados)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[29]:
```

	sum_sq	df	F	PR(>F)
C(grados)	3411.8	4.0	68.054521	1.963480e-09
Residual	188.0	15.0	NaN	NaN

```
[30]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

```
valor-p (Shapiro) = 0.7785351257478303
```





```
[31]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['grados'] == '20°']['numero']
grupo2 = df[df['grados'] == '40°']['numero']
grupo3 = df[df['grados'] == '60°']['numero']
grupo4 = df[df['grados'] == '80°']['numero']
grupo5 = df[df['grados'] == '100°']['numero']

stat, p = levene(grupo1, grupo2, grupo3, grupo4, grupo5)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.6159602096484009

No se rechaza ni shapiro ni levene

```
[32]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05
```

```

# Prueba de Tukey
tukey = pairwise_tukeyhsd(endog=df['numero'], groups=df['grados'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="grados", xlabel="numero")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====
group1 group2 meandiff p-adj  lower  upper  reject
-----
100°    20°   -35.75    0.0 -43.4801 -28.0199  True
100°    40°   -34.0     0.0 -41.7301 -26.2699  True
100°    60°   -28.0     0.0 -35.7301 -20.2699  True
100°    80°   -19.0     0.0 -26.7301 -11.2699  True
 20°    40°    1.75  0.9535  -5.9801   9.4801  False
 20°    60°    7.75  0.0493   0.0199  15.4801  True
 20°    80°   16.75  0.0001   9.0199  24.4801  True
 40°    60°    6.0   0.1696  -1.7301  13.7301  False
 40°    80°   15.0   0.0002   7.2699  22.7301  True
 60°    80°    9.0   0.0191   1.2699  16.7301  True
=====

```

```

[32]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')

```



```
[33]: #BLANCA ROCIO SILVA GALLEGOS
# ² (eta cuadrado)      Tamaño del efecto
# ~0.01                Pequeño
# ~0.06                Mediano
# ~0.14 o más         Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un ² de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(grados)'] / tabla_anova['sum_sq'].sum()
print(f"² (tamaño de efecto): {eta_squared:.3f}")
```

```
² (tamaño de efecto): 0.948
```

conforme va aumentando la temperatura aumenta el desgaste, entre 20 y 40 no hay diferencia significativa, entre 40 y 60 no hay diferencia

Temperatura en tableros electrónicos

Conclusión general:

La temperatura de envejecimiento afecta significativamente el deterioro de los tableros electrónicos. Los supuestos estadísticos fueron cumplidos y Tukey mostró que las temperaturas más altas generan

mayor deterioro. En general, los cambios entre temperaturas bajas son menos notables, mientras que a temperaturas elevadas el daño se incrementa de forma marcada.

5. En una empresa de manufactura se propone un tratamiento para reducir el porcentaje de productos defectuosos. Para validar esta propuesta se diseñó un experimento en el que se producía con o sin la propuesta de mejora. Cada corrida experimental consistió en producir un lote y la variable de respuesta es el porcentaje de producto defectuoso. Se hicieron 25 réplicas para cada tratamiento. Los datos obtenidos se muestran a continuación:

Tratamiento	Porcentaje de producto defectuoso
Con tratam.	5.3, 4.0, 4.0, 4.0, 2.6, 2.1, 5.1, 4.1, 4.1, 3.2, 5.1, 2.2, 4.1
Sin tratam.	8.0, 13.2, 7.2, 8.2, 9.1, 6.7, 12.6, 16.3, 9.2, 6.4, 7.2, 17.2, 12.3

[34]: *#BLANCA ROCIO SILVA GALLEGOS*

```
import pandas as pd
from io import StringIO

datos = '''
tratamiento,porcentaje
con,5.3
con,4.0
con,4.0
con,4.0
con,2.6
con,2.1
con,5.1
con,4.1
con,4.1
con,3.2
con,5.1
con,2.2
con,4.1

sin,8.0
sin,13.2
sin,7.2
sin,8.2
sin,9.1
sin,6.7
sin,12.6
sin,16.3
sin,9.2
sin,6.4
sin,7.2
sin,17.2
sin,12.3
```

```
'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df
```

```
[34]:
```

	tratamiento	porcentaje
0	con	5.3
1	con	4.0
2	con	4.0
3	con	4.0
4	con	2.6
5	con	2.1
6	con	5.1
7	con	4.1
8	con	4.1
9	con	3.2
10	con	5.1
11	con	2.2
12	con	4.1
13	sin	8.0
14	sin	13.2
15	sin	7.2
16	sin	8.2
17	sin	9.1
18	sin	6.7
19	sin	12.6
20	sin	16.3
21	sin	9.2
22	sin	6.4
23	sin	7.2
24	sin	17.2
25	sin	12.3

```
[35]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'porcentaje ~ C(tratamiento)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
```

```
tabla_anova
```

```
[35]:
```

	sum_sq	df	F	PR(>F)
C(tratamiento)	269.449615	1.0	37.102806	0.000003
Residual	174.293846	24.0	NaN	NaN

```
[36]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

```
valor-p (Shapiro) = 0.08240142335256262
```





```
[37]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['tratamiento'] == 'con']['porcentaje']
grupo2 = df[df['tratamiento'] == 'sin']['porcentaje']

stat, p = levene(grupo1, grupo2)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.006953158590874458


```
[38]: #BLANCA ROCIO SILVA GALLEGOS
# Si no se cumple el supuesto de normalidad o el de homoscedasticidad
from scipy.stats import boxcox
import matplotlib.pyplot as plt

# Transformación mediante el método box-cox
# Solo funciona si Y > 0
df["porcentaje_boxcox"], lambda_opt = boxcox(df["porcentaje"])
```

```
print(f"Lambda óptimo: {lambda_opt}")

plt.figure(figsize = (5, 5), dpi = 100)
plt.scatter(df["porcentaje"], df["porcentaje_boxcox"], color = "black")
plt.title("Variable trasformada mediante Box-Cox")
plt.xlabel("Variable real")
plt.ylabel("Variable trasformada")
plt.show()
```

Lambda óptimo: -0.05387226813423122



```
[39]: #BLANCA ROCIO SILVA GALLEGOS
df
```

```
[39]:   tratamiento  porcentaje  porcentaje_boxcox
0          con          5.3          1.594985
1          con          4.0          1.335793
2          con          4.0          1.335793
3          con          4.0          1.335793
```

4	con	2.6	0.931335
5	con	2.1	0.727305
6	con	5.1	1.559787
7	con	4.1	1.358694
8	con	4.1	1.358694
9	con	3.2	1.127458
10	con	5.1	1.559787
11	con	2.2	0.771947
12	con	4.1	1.358694
13	sin	8.0	1.967198
14	sin	13.2	2.408917
15	sin	7.2	1.872735
16	sin	8.2	1.989259
17	sin	9.1	2.081979
18	sin	6.7	1.807897
19	sin	12.6	2.368383
20	sin	16.3	2.591451
21	sin	9.2	2.091679
22	sin	6.4	1.766499
23	sin	7.2	1.872735
24	sin	17.2	2.637625
25	sin	12.3	2.347347

```
[40]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'porcentaje_boxcox ~ C(tratamiento)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[40]:
```

	sum_sq	df	F	PR(>F)
C(tratamiento)	5.040324	1.0	58.843753	6.583032e-08
Residual	2.055745	24.0	NaN	NaN

```
[41]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo_lineal.resid
```

```


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")


# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()

```

valor-p (Shapiro) = 0.5855089546322916





```
[42]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['tratamiento'] == 'con']['porcentaje_boxcox']
grupo2 = df[df['tratamiento'] == 'sin']['porcentaje_boxcox']

stat, p = levene(grupo1, grupo2)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.5435742179927381

```
[43]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['porcentaje_boxcox'],
    ↪groups=df['tratamiento'], alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="tratamiento", xlabel="porcentaje_boxcox")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj lower  upper  reject
-----
  con    sin    0.8806   0.0 0.6437 1.1175   True
-----

```

[43]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



[44]: #BLANCA ROCIO SILVA GALLEGOS
² (eta cuadrado) Tamaño del efecto

```

# ~0.01                Pequeño
# ~0.06                Mediano
# ~0.14 o más          Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un  $\eta^2$  de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(tratamiento)'] / tabla_anova['sum_sq'].
    ↪sum()
print(f" $\eta^2$  (tamaño de efecto): {eta_squared:.3f}")

```

η^2 (tamaño de efecto): 0.710

Tratamiento para reducir defectuosos

Conclusión general:

El tratamiento propuesto tiene un efecto significativo en la reducción del porcentaje de productos defectuosos. Debido a la falta de homogeneidad de varianzas inicial, fue necesario aplicar Box-Cox. Tras la corrección, Tukey confirmó que el tratamiento mejora de forma real la calidad del proceso productivo.

- Una compañía farmacéutica desea evaluar el efecto que tiene la cantidad de almidón en la dureza de las tabletas. Se decidió producir lotes con una cantidad determinada de almidón, y que las cantidades de almidón a aprobar fueran 2%, 5% y 10%. La variable de respuesta sería el promedio de la dureza de 20 tabletas de cada lote. Se hicieron 4 réplicas por tratamiento y se obtuvieron los siguientes resultados:

% de almidón	Dureza
2	4.3, 5.2, 4.8, 4.5
5	6.5, 7.3, 6.9, 6.1
10	9.0, 7.8, 8.5, 8.1

```

[45]: #BLANCA ROCIO SILVA GALLEGOS
import pandas as pd
from io import StringIO

datos = '''
almidon,dureza
2,4.3
2,5.2
2,4.8
2,4.5
5,6.5
5,7.3

```

```

5,6.9
5,6.1
10,9.0
10,7.8
10,8.5
10,8.1

'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df

```

```

[45]:      almidon  dureza
0         2     4.3
1         2     5.2
2         2     4.8
3         2     4.5
4         5     6.5
5         5     7.3
6         5     6.9
7         5     6.1
8        10     9.0
9        10     7.8
10       10     8.5
11       10     8.1

```

```

[46]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'dureza ~ C(almidon)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova

```

```

[46]:      sum_sq  df      F    PR(>F)
C(almidon) 26.726667  2.0  58.101449  0.000007
Residual    2.070000  9.0      NaN      NaN

```

```

[47]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro

```

```

import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")


# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()

```

valor-p (Shapiro) = 0.42952068080371164





```
[48]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['almidon'] == 2]['dureza']
grupo2 = df[df['almidon'] == 5]['dureza']
grupo3 = df[df['almidon'] == 10]['dureza']

stat, p = levene(grupo1, grupo2, grupo3)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.771773370798543

```
[49]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['dureza'], groups=df['almidon'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="almidon", xlabel="dureza")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj  lower  upper  reject
-----
      2      5        2.0 0.0006 1.0532 2.9468    True
      2     10        3.65    0.0 2.7032 4.5968    True
      5     10        1.65 0.0023 0.7032 2.5968    True
-----

```

[49]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



```
[50]: #BLANCA ROCIO SILVA GALLEGOS
# 2 (eta cuadrado)          Tamaño del efecto
# ~0.01                      Pequeño
# ~0.06                      Mediano
# ~0.14 o más               Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un 2 de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(almidon)'] / tabla_anova['sum_sq'].sum()
print(f" 2 (tamaño de efecto): {eta_squared:.3f}")
```

² (tamaño de efecto): 0.928

Porcentaje de almidón en tabletas

Conclusión general:

La cantidad de almidón influye directamente en la dureza de las tabletas. Se cumplieron los supuestos estadísticos y Tukey mostró que todos los niveles de almidón generan respuestas diferentes. En general, a mayor cantidad de almidón, mayor dureza del producto final.

7. Los datos que se presentan enseguida son rendimientos en toneladas por hectárea de un pasto con tres niveles de fertilización nitrogenada. El diseño fue completamente aleatorizado, con cinco repeticiones por tratamiento.

Niveles de nitrógeno	Rendimientos (ton/ha)
1	14.823, 14.676, 14.720, 14.5141, 15.065
2	25.151, 25.401, 25.131, 25.031, 25.267
3	32.605, 32.460, 32.256, 32.669, 32.111

```
[51]: #BLANCA ROCIO SILVA GALLEGOS
import pandas as pd
from io import StringIO

datos = '''
niveles,rendimientos

1a,14.823
1a,14.676
1a,14.720
1a,14.5141
1a,15.065
```

```

2b,25.151
2b,25.401
2b,25.131
2b,25.031
2b,25.267

3c,32.605
3c,32.460
3c,32.256
3c,32.669
3c,32.111

'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df

```

```

[51]:
niveles  rendimientos
0      1a      14.8230
1      1a      14.6760
2      1a      14.7200
3      1a      14.5141
4      1a      15.0650
5      2b      25.1510
6      2b      25.4010
7      2b      25.1310
8      2b      25.0310
9      2b      25.2670
10     3c      32.6050
11     3c      32.4600
12     3c      32.2560
13     3c      32.6690
14     3c      32.1110

```

```

[52]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'rendimientos ~ C(niveles)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)

```

```
tabla_anova
```

```
[52]:
```

	sum_sq	df	F	PR(>F)
C(niveles)	788.340773	2.0	10131.619332	4.298250e-20
Residual	0.466860	12.0	NaN	NaN

```
[53]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

```
valor-p (Shapiro) = 0.8890610190283172
```





```
[54]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['niveles'] == "1a"]['rendimientos']
grupo2 = df[df['niveles'] == "2b"]['rendimientos']
grupo3 = df[df['niveles'] == "3c"]['rendimientos']

stat, p = levene(grupo1, grupo2, grupo3)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.5977763142684792

```
[55]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['rendimientos'], groups=df['niveles'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="niveles", xlabel="rendimientos")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj  lower  upper  reject
-----
    1a    2b  10.4366   0.0 10.1038 10.7694   True
    1a    3c  17.6606   0.0 17.3278 17.9934   True
    2b    3c   7.224   0.0  6.8912  7.5568   True
-----

```

[55]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



```
[56]: #BLANCA ROCIO SILVA GALLEGOS
# 2 (eta cuadrado)          Tamaño del efecto
# ~0.01                      Pequeño
# ~0.06                      Mediano
# ~0.14 o más               Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un 2 de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(niveles)'] / tabla_anova['sum_sq'].sum()
print(f" 2 (tamaño de efecto): {eta_squared:.3f}")
```

² (tamaño de efecto): 0.999

Fertilización nitrogenada

Conclusión general:

El nivel de fertilización nitrogenada tiene un efecto significativo en el rendimiento del pasto. Los supuestos estadísticos fueron validados y Tukey confirmó diferencias claras entre todos los niveles. En general, incrementar el nitrógeno aumenta el rendimiento por hectárea.

- Un químico del departamento de desarrollo de un laboratorio farmacéutico desea conocer cómo influye el tipo de aglutinante utilizado en tabletas de ampicilina de 500 mg en el porcentaje de friabilidad; para ello, se eligen los siguientes aglutinantes: polivinilpirrolidona (PVP), carboximetilcelulosa sódica (CMC) y grenetina (Gre). Los resultados del diseño experimental son los siguientes:

Aglutinante	% de friabilidad
PVP	0.485, 0.250, 0.073, 0.205, 0.161
CMC	9.64, 9.37, 9.53, 9.86, 9.79
Gre	0.289, 0.275, 0.612, 0.152, 0.137

```
[57]: #BLANCA ROCIO SILVA GALLEGOS
import pandas as pd
from io import StringIO

datos = '''
aglutinante,friabilidad

PVP,0.485
PVP,0.250
PVP,0.073
PVP,0.205
PVP,0.161
```

```

CMC,9.64
CMC,9.37
CMC,9.53
CMC,9.86
CMC,9.79

Gre,0.289
Gre,0.275
Gre,0.612
Gre,0.152
Gre,0.137

'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df

```

```

[57]:      aglutinante  friabilidad
0          PVP          0.485
1          PVP          0.250
2          PVP          0.073
3          PVP          0.205
4          PVP          0.161
5          CMC          9.640
6          CMC          9.370
7          CMC          9.530
8          CMC          9.860
9          CMC          9.790
10         Gre          0.289
11         Gre          0.275
12         Gre          0.612
13         Gre          0.152
14         Gre          0.137

```

```

[58]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'friabilidad ~ C(aglutinante)', data=df).fit()

```

```
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[58]:
```

	sum_sq	df	F	PR(>F)
C(aglutinante)	292.920971	2.0	4420.972597	6.198213e-18
Residual	0.397543	12.0	NaN	NaN

```
[59]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

```
valor-p (Shapiro) = 0.42143454193876007
```





```
[60]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['aglutinante'] == "PVP"]['friabilidad']
grupo2 = df[df['aglutinante'] == "CMC"]['friabilidad']
grupo3 = df[df['aglutinante'] == "Gre"]['friabilidad']

stat, p = levene(grupo1, grupo2, grupo3)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.8018412374552168

```
[61]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['fiabilidad'], groups=df['aglutinante'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="aglutinante", xlabel="fiabilidad")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj  lower  upper  reject
-----
CMC     Gre    -9.345    0.0  -9.6521 -9.0379   True
CMC     PVP    -9.4032    0.0  -9.7103 -9.0961   True
Gre     PVP    -0.0582    0.87 -0.3653  0.2489   False
-----

```

[61]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



```
[62]: #BLANCA ROCIO SILVA GALLEGOS
# 2 (eta cuadrado)          Tamaño del efecto
# ~0.01                      Pequeño
# ~0.06                      Mediano
# ~0.14 o más               Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un 2 de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(aglutinante)'] / tabla_anova['sum_sq'].
↪sum()
print(f"2 (tamaño de efecto): {eta_squared:.3f}")
```

² (tamaño de efecto): 0.999

Tipo de aglutinante

Conclusión general:

El tipo de aglutinante afecta significativamente la friabilidad de las tabletas. Los análisis mostraron que CMC se comporta de forma diferente y menos favorable que los otros aglutinantes. En general, PVP y Gre producen resultados similares y más adecuados.

9. Se cultivaron cuatro diferentes clonas de *agave tequilana* bajo un mismo esquema de manejo. Se quiere saber qué clona es la que responde mejor a dicho manejo, evaluando el nivel de respuesta con el porcentaje de azúcares reductores totales en base húmeda. Los datos se muestran a continuación:

Clona	Porcentaje de azúcares reductores totales
1	8.69, 6.68, 6.83, 6.43, 10.30
2	8.00, 16.41, 12.43, 10.99, 15.53
3	17.39, 13.73, 15.62, 17.05, 15.42
4	10.37, 9.16, 8.83, 4.40, 10.38

```
[63]: #BLANCA ROCIO SILVA GALLEGOS
import pandas as pd
from io import StringIO

datos = '''
clona,porcentaje

1,8.69
1,6.68
1,6.83
1,6.43
```

```

1,10.30

2,8.00
2,16.41
2,12.43
2,10.99
2,15.53

3,17.39
3,13.73
3,15.62
3,17.05
3,15.42

4,10.37
4,9.16
4,8.83
4,4.40
4,10.38

'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df

```

```

[63]:
      clona  porcentaje
0         1         8.69
1         1         6.68
2         1         6.83
3         1         6.43
4         1        10.30
5         2         8.00
6         2        16.41
7         2        12.43
8         2        10.99
9         2        15.53
10        3        17.39
11        3        13.73
12        3        15.62
13        3        17.05
14        3        15.42
15        4        10.37
16        4         9.16
17        4         8.83
18        4         4.40

```

```
[64]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'porcentaje ~ C(clona)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[64]:
```

	sum_sq	df	F	PR(>F)
C(clona)	209.90716	3.0	12.327073	0.000198
Residual	90.81676	16.0	NaN	NaN

```
[65]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

```
valor-p (Shapiro) = 0.7677173153296
```





```
[66]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['clona'] == 1]['porcentaje']
grupo2 = df[df['clona'] == 2]['porcentaje']
grupo3 = df[df['clona'] == 3]['porcentaje']
grupo4 = df[df['clona'] == 4]['porcentaje']

stat, p = levene(grupo1, grupo2, grupo3, grupo4)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.4290096340206233

```
[67]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['porcentaje'], groups=df['clona'],
    ↪alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="clona", xlabel="porcentaje")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj  lower  upper  reject
-----
     1     2    4.886 0.0237   0.575   9.197    True
     1     3    8.056 0.0003   3.745  12.367    True
     1     4    0.842 0.9428  -3.469   5.153   False
     2     3     3.17 0.1939  -1.141   7.481   False
     2     4   -4.044 0.0699  -8.355   0.267   False
     3     4   -7.214 0.001 -11.525  -2.903    True
-----

```

[67]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



```
[68]: #BLANCA ROCIO SILVA GALLEGOS
# 2 (eta cuadrado)          Tamaño del efecto
# ~0.01                      Pequeño
# ~0.06                      Mediano
# ~0.14 o más                Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un 2 de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(clona)'] / tabla_anova['sum_sq'].sum()
print(f" 2 (tamaño de efecto): {eta_squared:.3f}")
```

² (tamaño de efecto): 0.698

Clonas de agave

Conclusión general:

Las clonas de agave responden de manera distinta al mismo manejo agrícola. Los supuestos se cumplieron y Tukey evidenció diferencias entre algunas clonas. En términos generales, la clona 3 presentó mejor desempeño que varias de las otras clonas evaluadas.

- Uno de los defectos que causan mayor desperdicio en la manufactura de discos ópticos compactos son los llamados “cometas”. Típicamente, se trata de una partícula que opone resistencia al fluido en la etapa de entintado. Se quiere comprobar de manera experimental la efectividad de un tratamiento de limpieza de partículas que está basado en fuerza centrípeta y aire ionizado. A 12 lotes de 50 CD se les aplica el tratamiento y a otros 12 lotes no se les aplica; en cada caso se mide el porcentaje de discos que presentan cometas, los resultados son los siguientes:

Con tratamiento	Sin tratamiento
5.30	8.02
4.03	13.18
4.00	7.15
2.56	9.11
5.06	8.23
4.06	16.3
2.08	9.20
4.03	6.35
2.04	7.15
1.18	8.66

```
[69]: #BLANCA ROCIO SILVA GALLEGOS
import pandas as pd
from io import StringIO

datos = '''
tratamiento,porcentaje

con,5.30
sin,8.02
con,4.03
sin,13.18
con,4.00
sin,7.15
con,2.56
sin,9.11
con,5.06
sin,8.23
con,4.06
sin,16.3
con,2.08
sin,9.20
con,4.03
sin,6.35
con,2.04
sin,7.15
con,1.18
sin,8.66

'''

df = pd.read_csv(StringIO(datos))
df.reset_index(drop=True, inplace=True)

df
```

```
[69]:
```

	tratamiento	porcentaje
0	con	5.30
1	sin	8.02
2	con	4.03
3	sin	13.18
4	con	4.00
5	sin	7.15
6	con	2.56
7	sin	9.11
8	con	5.06
9	sin	8.23

10	con	4.06
11	sin	16.30
12	con	2.08
13	sin	9.20
14	con	4.03
15	sin	6.35
16	con	2.04
17	sin	7.15
18	con	1.18
19	sin	8.66

```
[70]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'porcentaje ~ C(tratamiento)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[70]:
```

	sum_sq	df	F	PR(>F)
C(tratamiento)	174.109005	1.0	30.605669	0.00003
Residual	102.398090	18.0	NaN	NaN

```
[71]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")


# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
```

```
plt.show()
```

valor-p (Shapiro) = 0.013152795271816523





```
[72]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['tratamiento'] == "con"]['porcentaje']
grupo2 = df[df['tratamiento'] == "sin"]['porcentaje']

stat, p = levene(grupo1, grupo2)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.30433662983094306


```
[73]: #BLANCA ROCIO SILVA GALLEGOS
# Si no se cumple el supuesto de normalidad o el de homoscedasticidad
from scipy.stats import boxcox
import matplotlib.pyplot as plt

# Transformación mediante el método box-cox
# Solo funciona si Y > 0
df["observaciones_boxcox"], lambda_opt = boxcox(df["porcentaje"])
```

```
print(f"Lambda óptimo: {lambda_opt}")

plt.figure(figsize = (5, 5), dpi = 100)
plt.scatter(df["porcentaje"], df["observaciones_boxcox"], color = "black")
plt.title("Variable trasformada mediante Box-Cox")
plt.xlabel("Variable real")
plt.ylabel("Variable trasformada")
plt.show()
```

Lambda óptimo: 0.3206116786631181



```
[74]: #BLANCA ROCIO SILVA GALLEGOS
df
```

```
[74]:
```

	tratamiento	porcentaje	observaciones_boxcox
0	con	5.30	2.204887
1	sin	8.02	2.961045
2	con	4.03	1.757241
3	sin	13.18	4.010783

4	con	4.00	1.745573
5	sin	7.15	2.741280
6	con	2.56	1.097026
7	sin	9.11	3.214603
8	con	5.06	2.126373
9	sin	8.23	3.011640
10	con	4.06	1.768850
11	sin	16.30	4.513380
12	con	2.08	0.825494
13	sin	9.20	3.234598
14	con	4.03	1.757241
15	sin	6.35	2.522523
16	con	2.04	0.801013
17	sin	7.15	2.741280
18	con	1.18	0.169985
19	sin	8.66	3.112566

```
[75]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.formula.api import ols
import statsmodels.api as sm

# Nivel de significancia = 0.05
# H0: Todas las medias son iguales
# H1: Al menos una media es distinta

# Realizar el modelo ANOVA de dos vías
modelo_lineal = ols(f'observaciones_boxcox ~ C(tratamiento)', data=df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal, typ=2)
tabla_anova
```

```
[75]:
```

	sum_sq	df	F	PR(>F)
C(tratamiento)	15.859833	1.0	38.91081	0.000007
Residual	7.336701	18.0	NaN	NaN

```
[76]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo_lineal.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")


# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
```

```
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

valor-p (Shapiro) = 0.9455348292593064





```
[77]: #BLANCA ROCIO SILVA GALLEGOS
from scipy.stats import levene

# Supón que tienes un DataFrame df con columnas 'respuesta' y 'grupo'
grupo1 = df[df['tratamiento'] == "con"]['observaciones_boxcox']
grupo2 = df[df['tratamiento'] == "sin"]['observaciones_boxcox']

stat, p = levene(grupo1, grupo2)
print(f"p-valor de Levene: {p}")
```

p-valor de Levene: 0.7008973474327473

```
[78]: #BLANCA ROCIO SILVA GALLEGOS
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

nivel_de_significancia = 0.05

# Prueba de Tukey
```

```

tukey = pairwise_tukeyhsd(endog=df['observaciones_boxcox'],
    groups=df['tratamiento'], alpha=nivel_de_significancia)

# Mostrar los resultados
print(tukey)

# Gráfico de las diferencias entre grupos
tukey.plot_simultaneous(ylabel="tratamiento", xlabel="observaciones_boxcox")

plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)  # superior
plt.title("Múltiples comparaciones entre todos los pares (Tukey)")

```


Multiple Comparison of Means - Tukey HSD, FWER=0.05

```

=====
group1 group2 meandiff p-adj lower upper reject
-----
con     sin     1.781   0.0  1.1812 2.3808  True
-----

```

[78]: Text(0.5, 1.0, 'Múltiples comparaciones entre todos los pares (Tukey)')



[79]: #BLANCA ROCIO SILVA GALLEGOS
² (eta cuadrado) Tamaño del efecto

```

# ~0.01                Pequeño
# ~0.06                Mediano
# ~0.14 o más          Grande

# Se interpreta como el coeficiente de determinación

# Estos valores pueden variar según la disciplina. En estudios de ciencias
# sociales, un  $\eta^2$  de 0.06 puede ser muy significativo;
# en física o ingeniería, quizá se espera más.

eta_squared = tabla_anova['sum_sq']['C(tratamiento)'] / tabla_anova['sum_sq'].
    ↪sum()
print(f" $\eta^2$  (tamaño de efecto): {eta_squared:.3f}")

```

η^2 (tamaño de efecto): 0.684

Limpieza de partículas en discos

Conclusión general:

El tratamiento de limpieza influye significativamente en la reducción de defectos tipo “cometas”. Los resultados muestran que aplicar el tratamiento disminuye de manera real el porcentaje de productos defectuosos, por lo que el tratamiento es efectivo.